

Raters' Comments Study 2

Rater A:

Bei den ersten Papern haben mich die Kriterien, die auf den Konsensus hinweisen immer etwas irritiert, da diese (so wie ich diese verstanden habe) extrem selten zugetroffen haben, aber sehr detailliert beschrieben sind, wodurch man immer direkt über 10 Kriterien "abgelehnt" hat. Im Gegensatz dazu waren spätere Kriterien gefühlt etwas breiter formuliert bzw. haben direkt mehrere Teilaspekte umfasst (z.B. bei 6e, der Zeitraum der Präregistrierung, Erhebung und Analyse), weshalb ich hier öfter auf die Antwortkategorien "partly applies" oder "unsure" zurückgreifen und meine Angabe in den Kommentaren genauer erläutern musste. Bei Kriterium 8d war ich mir immer unsicher, wann dieses genau erfüllt sein sollte, da die Beschreibung des Beispiels für mich etwas unspezifisch war und auch das Beispiel, relativ unkonkret war (im Gegensatz zu z.B. 8a, bei dem ein genaues Vorgehen gegeben wurde, an dem man sich orientieren konnte).

With the first papers, the criteria regarding consensus always confused me somewhat, as (as I understood them) they were extremely rarely applicable, but were described in great detail, which always led to the immediate "rejection" of more than 10 criteria. In contrast, later criteria felt somewhat broader in their wording or directly encompassed several sub-aspects (e.g., in 6e, the time of pre-registration, collection, and analysis), which is why I often had to resort to the answer categories "partly applies" or "unsure" and explain my answer in more detail in the comments. With criterion 8d, I was always unsure when exactly it should be met, as the description of the example seemed somewhat unspecific to me, and the example itself was also relatively vague (in contrast to, for example, 8a, where a precise procedure was given that one could follow).

Rater B:

Ich glaube, ich habe es auch irgendwann mal als Kommentar geschrieben, aber falls nicht, nochmal hier: Ich finde die letzten Consensus Fragen (zu "Knowledge") ein bisschen schwierig, da ich hier eigentlich immer angekreuzt habe, dass Sie zutrifft (applies) sobald ich dies bei irgendeiner anderen Consensus Frage auch angekreuzt habe. Denn irgendwie ist ja jeder Consensus auch zusätzliche Knowledge im jeweiligen Feld. Außerdem fand ich es bei einigen Fragen schwierig einzuschätzen, wie ich die 3-Stufige Skala verwenden sollte, da z.B. Consensus ja entweder vorliegt oder nicht... Ich habe mich dementsprechend öfter gefragt, wann oder wie ich die Mittelkategorie verwenden soll. Auch bei der Formulierung "results that fundamentally challenge documented consensus" fiel es mir schwer zu antworten. Denn, wenn kein vorheriger Consensus im Text genannt wurde, kann ich nicht einschätzen, ob dieser hier erweitert wird, und die Formulierung klingt auch sehr stark - liegt eine fundamentale

neue Erkenntnis vor? - ist in der Forschung grundsätzlich eher selten und als Außenstehende schwer zu sagen.

Letztendlich habe ich nach mehr und mehr der Bewertungen festgestellt, dass ich einige Kategorien bei den ersten Bewertungen noch nicht besonders gut einschätzen konnte. Ich hatte zum Beispiel vor dieser Arbeit noch nicht so viel Kontakt zu Consensus und fand es daher trotz kurzer Erklärung schwer einzuschätzen was genau damit gemeint ist. Für mich wäre es hilfreich gewesen ein kurzes Text-Beispiel zu jedem Punkt zu haben.

I think I wrote it as a comment at some point, but in case not, here it is again: I find the last consensus questions (on "Knowledge") a bit difficult, since I always checked that it applies as soon as I had checked it for any other consensus question. After all, every consensus is also additional knowledge in the respective field. I also found it difficult to assess how to use the 3-level scale for some questions, since (e.g.) consensus either exists or it doesn't... Accordingly, I often wondered when or how to use the middle category.

I also found it difficult to answer the phrase "results that fundamentally challenge documented consensus" Because if no previous consensus was mentioned in the text, I can't assess whether it is expanded upon here, and the wording also sounds very strong – has there been a fundamentally new insight? - is generally rather rare in research and difficult to judge as an outsider.

Ultimately, after more and more evaluations, I realized that I hadn't been able to assess some categories very well in my initial evaluations. For example, I hadn't had much contact with the Consensus issue before this work and therefore found it difficult to assess exactly what it meant, despite the brief explanations being given. It would have been helpful for me to have a short text example for each point.

Rater C:

Bei consensus war mir z.B. nicht ganz klar, wie detailliert beschrieben werden muss, wie dieser erreicht wurde (also z.B. reichte es laut der kurzen Beschreibung im Rating-Schema ja nicht, nur zu erwähnen, dass man sich auf ein consensus Dokument bezieht). Weiterhin war mir nicht klar, ob es auch als consensus zählt, wenn die Autoren etwas kodieren oder Ähnliches. Wie schon erwähnt: Wenn bestimmte Dinge nicht im Text erwähnt werden (z.B. steht weder drin, dass eine Präregistrierung gemacht wurde, noch dass keine gemacht wurde, oder ob die Stichprobe repräsentativ ist oder nicht) - sollte man dann angeben, dass es nicht zutrifft, weil man davon ausgehen muss, dass keine Präregistrierung gemacht wurde, oder soll man dann unclear angeben? Insbesondere auch in solchen Fällen, in denen eine Präregistrierung gemacht wurde und man soll angeben, ob Abweichungen kenntlich gemacht wurden: hier entstand für mich das Problem, dass ich does not apply angeklickt

habe, wenn es Abweichungen gab, die nicht beschrieben wurden, aber auch, wenn keine Abweichungen beschrieben wurden, weil es keine gab. Partly applies fand ich generell schwierig, insbesondere wenn Items eigentlich klare Anforderungen hatten. Ich hatte das Gefühl, dass ich mir bei fast keinem der Items ein Szenario vorstellen konnte, wo man das hätte anklicken können. Z.B. Hatte ich überlegt, ob bei 9c [Analysis code (e.g., an R-script or SPSS syntax) is made openly available. Judging this requires checking whether a link provided in the article to an online repository actually works] partly applies zutreffen würde, wenn es keinen Link gibt. Also es war dann unklar, was quasi die Mindestanforderungen sind, damit es nicht zwangsläufig does not apply ist. 9b [Open data is accompanied by meta-data that (at least) documents all variables in the dataset in a manner that enables new analyses without requiring further interactions with the people who collected the data]: da war ich mir unsicher, was da alles dazu zählt / in welcher Form dies sein kann.

With consensus, it wasn't entirely clear to me how detailed a description of how it was achieved had to be (e.g., according to the brief description in the rating scheme, it wasn't enough to simply mention that one was referring to a consensus document). Furthermore, it wasn't clear to me whether it also counts as consensus if the authors code something or something similar.

As already mentioned: If certain things aren't mentioned in the text (e.g., it doesn't say that pre-registration was done, or that none was done, or whether the sample is representative or not) - should one then state that it doesn't apply because one must assume that no pre-registration was done, or should one then state "unclear"? Especially in cases where pre-registration was done and one is asked to indicate whether deviations were identified: here, I encountered the problem that I clicked "does not apply" when there were deviations that were not described, but also when no deviations were described because none existed.

I generally found the "partly applies" option difficult, especially when items actually had clear requirements. I felt that I couldn't imagine a scenario for almost any of the items where one could have clicked this. For example, I had considered whether "partly applies" would apply for 9c [Analysis code (e.g., an R script or SPSS syntax) is made openly available. Judging this requires checking whether a link provided in the article to an online repository actually works] if there was no link. So, it was unclear what the minimum requirements were so that it wouldn't necessarily be "does not apply."

9b [Open data is accompanied by meta-data that (at least) documents all variables in the dataset in a manner that enables new analyses without requiring further interactions with the people who collected the data]: I was unsure what this entails / in which form this may apply.

Rater D:

Ich fand die consensus Fragen schwierig und habe da dann immer nur was angekreuzt, wenn explizit irgendwas mit consensus auch im Paper stand. Die Frage nach Metadaten, die die Variablen beschreiben fand ich teilweise auch uneindeutig, also ist gemeint ein extra Dokument wie ein Codebook oder reichen Anmerkungen zum Beispiel im RStudio Dokument, was wo gemacht wurde... Ansonsten habe ich meine Anmerkungen immer ins Feld mit dazu geschrieben. Insgesamt bin ich gut zurechtgekommen.

I found the consensus questions difficult and only checked these boxes if the paper explicitly mentioned something about consensus. I also found the question about metadata describing the variables somewhat ambiguous – does this mean a separate document like a codebook or, for example, would it be sufficient to have notes in the RStudio document that describe what was done where... Otherwise, I always wrote my comments into the respective field. Overall, I managed well.

Rater E:

Generell braucht man ein bisschen Übung mit dem Rating-Schema, das ist, denke ich, normal und danach kann man damit super arbeiten. Die Punkte 1-4 fand ich teilweise aber schwer einzuschätzen. Ich hatte vorher auch ehrlich gesagt noch nicht mit dem Begriff "Consensus Document" gearbeitet und war mir dabei dann immer am unsichersten. Vielleicht wäre es da sinnvoll, die Kriterien ein bisschen genauer zu erklären.

In general, you need a bit of practice with the rating scheme, which I think is normal, and after that, you'll be able to work with it really well. However, I found points 1-4 somewhat difficult to assess. To be honest, I hadn't worked with the term "consensus document" before, and I was thus most unsure about it. Perhaps it would be helpful to explain the criteria in a little more detail.

Rater F:

Bei den verschiedenen Arten von Consensus (bzgl. state of knowledge, measurement etc.) habe ich mich gefragt, ob die aktuellen Arten von Consensus alles abdecken. Es könnte auch Paper geben, die in eine andere Kategorie von Consensus fallen (z.B. bzgl. Results Reporting, innerwissenschaftlichen Reformvorschlägen). Vielleicht könnte man hier noch eine offene Kategorie hinzufügen, für alle sonstigen Arten von Consensus, die noch nicht abgedeckt wurden. - Es wäre hilfreich dem Rating-Schema noch Explikationen und Beispiele zu den einzelnen Kategorien hinzuzufügen und Beschreibungen der Anker, z.B. wann kreuzt man "partly applies" an (oder soll das nur die absolute Ausnahme sein?), da scheint es sehr viel Spielraum zu geben. Gerade in Zweifelsfällen könnten

Rater*innen dann nochmal einen Blick in die ausführlicheren Beschreibungen werfen. Es gab einige Kategorien/Fragen, die auch nicht ganz eindeutig formuliert sind (siehe einzelne Kommentare), z.B. die Frage, ob alle Daten, Materialien etc. in einem Ordner liegen (Was ist z.B., wenn nur Daten und Materialien vorhanden sind und kein Code, erstere aber im selben Ordner/Projekt liegen). Andere Kategorien könnten m.E. falsch verstanden werden, gerade wenn sich Rater*innen noch nicht so gut auskennen mit wissenschaftlichen Papern (z.B. könnte eine Regressionsgleichung in der Einleitung einfach als formales Modell verstanden werden). - Wie ist mit Simulationsstudien umzugehen? Es wird an einer Stelle von "measured variables" gesprochen und ob diese zu den Parametern des Modells eindeutig zugeordnet werden. Kann hier eine Simulationsstudie einen Ratingpunkt bekommen? Auch Simulationsstudien könnten höhere oder geringere Power haben, zählen diese genauso?

- Bzgl. Metaanalysen würde ich mich fragen, ob das Bewertungssystem fair ist gegenüber denen, die mit großem Aufwand die Daten der Primärstudien erhoben, und möglicherweise dann trotzdem eine deutlich geringere Power haben als diejenigen, die "nur" eine Metaanalyse durchführen.

- Studien mit Präregistrierungen haben nach meinem subjektiven Eindruck eindeutig am meisten Zeit und Konzentration beim Raten verlangt. Gerade hier fand ich bei (komplexen) Studien die Einschätzungen teilweise sehr schwierig (v.a., wenn Autor*innen andere Beschreibungen in der Präregistrierung verwendet haben, die aber z.T. das gleiche meinen). Hier war ich mir mit am unsichersten beim Raten.

Regarding the different types of consensus (regarding state of knowledge, measurement, etc.), I wondered whether the current types of consensus do cover everything. There could also be papers that fall into a different category of consensus (e.g., regarding results reporting, science reform proposals). Perhaps an open category could be added here for all other types of consensus that have not yet been covered. It would be helpful to add explanations and examples for the individual categories to the rating scheme, as well as descriptions of the anchors, e.g., when should one select "partly applies" (or should that only be the absolute exception?). There seems to be a lot of leeway there. Especially in cases of doubt, raters could then take another look at the more detailed descriptions. There were some categories/questions that weren't entirely clearly formulated (see individual comments), e.g., the question of whether all data, materials, etc., are in one folder (what happens, for example, if only data and materials are available but no code, but the former are in the same folder/project). Other categories, in my opinion, could be misunderstood, especially if raters aren't yet very familiar with scientific papers (e.g., a regression equation in the introduction could simply be viewed as a formal model). - How should simulation studies be handled? At one point, "measured variables" are mentioned and whether these can be clearly assigned to the model parameters. Can a simulation study receive a rating point here? Simulation studies could also have higher or lower power; do they count the same?

- Regarding meta-analyses, I would question whether the rating system is fair to those who have put considerable effort into collecting data in primary studies, and who may still have significantly lower power than those who "only" conduct a meta-analysis.

- In my subjective impression, rating studies with pre-registrations clearly required the most time and concentration. I found the assessments particularly difficult with (complex) studies (especially when authors used different descriptions in the pre-registration, but which partly meant the same thing). This was one of the areas where I was most unsure about my ratings.

Rater G:

Ich fand es am Anfang ein wenig schwierig einzuschätzen, weil ich noch nicht so wusste, was ein consensus document ist. Das wurde erst im Laufe der Zeit, als ich selbst auch so ein consensus document mal vorliegen hatte, klar. Außerdem fand ich, dass der Fragebogen bei manchen Papern, in denen eben keine Daten erhoben wurde, sondern nur etwas dokumentiert wurde, unpassend war, da er schon eher auf Datenerhebung ausgerichtet ist meiner Meinung nach. Genauso waren die Fragen zur Präregistrierung eben unnötig, wenn gar keine Präregistrierung stattfand. Vielleicht könnte man da erst abfragen, ob diese überhaupt stattfand und dann die weiteren Punkte abfragen.

I found it a little difficult to assess at first because I didn't really know what a consensus document was. This only became clear over time, when I had an actual consensus document in front of me. I also found that the questionnaire was inappropriate for some papers in which no data was collected, but rather something was simply documented, as it is focused on data collection, in my opinion. Similarly, the questions about pre-registration were unnecessary if no pre-registration had taken place at all. Perhaps one could first ask whether pre-registration had taken place at all and then ask the additional questions.

Rater H:

Generell: Ich finde es schwer Consensus zu definieren. Einerseits hat man manchmal Dokumente, die klar so gelabelt sind, aber manchmal hat man Dokumente, die eigentlich in ihrer Funktion Consensus Dokumente sind, aber nicht so benannt werden. Lehrbücher sind z.B. für mich ein Grenzfall. Wenn ich [AUTOREN] zitieren würde um eine Methode, die ich verwende zu rechtfertigen, ist das natürlich kein explizites Consensus Dokument, aber es erfüllt die gleiche Rolle, weil sich gefühlt jeder darauf bezieht. Vielleicht müsste man daher da die Sprache erweitern, um Dinge mit einzubeziehen, die sich einfach etabliert haben. Ein anderes Beispiel wäre das [MESSINSTRUMENT]. Verwendet jeder und man kann sagen, dass ein Consensus vorherrscht, dass das der "Goldstandard" ist. Vielleicht sollte das in Bezug auf die 3a (etc.) Fragen mit aufgenommen werden. So etwas wie: "Uses or relies on established practices either defined in a consensus paper or by common use of a certain methodology in the

specified field." Das öffnet natürlich Pandoras Box der Uneindeutigkeit, aber wenn es eine Stelle gibt, an der man vielleicht noch weiter daran arbeiten kann, dann das.

Zur eigenen Erfahrung kann ich sagen, dass man eindeutig schneller wird, je länger man das benutzt. Beim letzten Rating [AUTOREN] hatte ich jetzt geschaut, wie schnell ich das wirklich schaffen kann, wenn ich es drauf anlege. Es hatte auch nur 9 Seiten, aber ich habe das in 10 Minuten geschafft, was schon echt schnell ist. (Natürlich auch fehleranfälliger, aber ich dachte das wäre als Erfahrungswert interessant). Bei den anderen habe ich mir natürlich mehr Zeit gelassen.

In general: I find it difficult to define consensus. On the one hand, you sometimes have documents that are clearly labeled as such, but sometimes you have documents that are actually consensus documents in their function, but aren't named that way. Textbooks, for example, are a borderline case for me. If I were to cite [AUTHORS] to justify a method I use, it's obviously not an explicit consensus document, but it fulfils the same role because it seems like everyone refers to it. Perhaps the language should therefore be expanded to include things that have simply become established. Another example would be the [MEASURE]. Everyone uses it, and you can say that there is a consensus that it's the "gold standard." Perhaps this should be included in relation to the 3.a (etc.) questions. Something like: "Uses or relies on established practices either defined in a consensus paper or by common use of a certain methodology in the specified field." This, of course, opens a Pandora's box of ambiguity, but if there's one area where perhaps further work can be done, it's this.

From my own experience, I can say that you definitely get faster the longer you use it. In the last rating [AUTHORS], I looked at how quickly I could actually complete it if I really wanted to. It was only 9 pages long, but I managed it in 10 minutes, which is pretty fast. (Of course, it's also more error-prone, but I thought it would be an interesting learning experience.) With the others, I obviously took more time.